


推理引擎-Kernel优化

间接优化Indirect



ZOMI



Talk Overview

1. 推理系统介绍：推理系统架构 – 推理引擎架构
2. 模型小型化：CNN小型化结构 – Transform小型化结构
3. 离线优化压缩：低比特量化 – 模型剪枝 – 知识蒸馏
4. 模型转换与优化：模型转换细节 - 计算图优化
5. Kernel 优化
 - 算法优化 (Winograd / Strassen)
 - 内存布局 (NC1HWC0 / NCHW4)
 - 汇编优化 (指令与汇编)
 - 调度优化
6. Runtime 优化

推理引擎架构

- 高性能算子层
- 算子优化
 - 算子执行
 - 算子调度



Talk Overview

Conv Kernel 优化

- What is Convolution - 卷积的概念
- Im2Col Optimizer - Im2Col 优化算法
- Spatial Pack Optimizer – 空间组合优化
- Winograd Optimizer – Winograd 优化算法
- Indirect Algorithm – QNNPACK 间接卷积优化



间接卷积

优化算法

基本介绍

- [QNNPACK](#) (Quantized Neural Networks PACKage) 是 Marat Dukhan (Facebook) 开发的专门用于量化神经网络计算的加速库，其卓越的性能表现一经开源就击败了几乎全部已公开的加速算法
 -

基本介绍



Device	non-1x1	1x1 stride-2
Samsung Galaxy S8	+10.97%	+8.02%
Google Pixel 2 XL	+23.26%	+0.84%
Google Pixel 3	+4.31%	+0.51%


Table 3. Geomean performance of modified GEMM primitive relative to standard GEMM primitive on 1x1 and non-1x1 Convolutions in ResNet-18 model.

Device	non-1x1	1x1 stride 1
Samsung Galaxy S8	+5.70%	-1.84%
Google Pixel 2 XL	+11.29%	-0.25%
Google Pixel 3	+2.67%	-1.91%

Table 4. Geomean performance of modified GEMM primitive relative to standard GEMM primitive on 1x1 and non-1x1 Convolutions in SqueezeNet 1.0 model.


矩阵乘优化 Im2col 算法回顾

- 在计算 $MR \times NR$ 小块时，传统 GEMM 的方法是对 K 维度上拆分，在一次计算 kernel 处理中，仅计算 K 维的局部数据。那么在每次计算 kernel 处理过程，都会发生对输出的加载和存储。




矩阵乘优化 Im2col 算法回顾

- 在计算 $MR \times NR$ 小块时，传统 GEMM 的方法是对 K 维度上拆分，在一次计算 kernel 处理中，仅计算 K 维的局部数据。那么在每次计算 kernel 处理过程，都会发生对输出的加载和存储。




矩阵乘优化 Im2col 算法回顾

- 在计算 $MR \times NR$ 小块时，传统的方法是在 K 维度上拆分，在一次计算 Kernel 处理中，仅计算 K 维的局部。那么在每次计算 Kernel 的处理中，都会发生对输出的加载和存储。




QNNPACK 算法思想

- QNNPACK 做法将整个 K 维全部在计算 Kernel 中处理完，消除了输出部分和的访存。这里所说的「将整个 K 维全部」并不是指 K 维不进行拆分，而是指拆分后不和其他维度交换，实际计算中 K 维会以 2^n 为基础进行拆分。




QNNPACK 算法思想

- Im2col 优化算法存在两个问题：1) 第占用大量的额外内存；2) 需要对输入进行额外的数据拷贝。这两点如何才能解决呢？
- 间接卷积算法给出的答案是间接缓冲区（ Indirect Buffer ），对内存重新组织（ Repacking ）可以改进高速缓存命中率，从而提高性能。




Indirect Convolution Algorithm 工作流程

- Indirect 算法在输入缓冲区基础上构建间接缓冲区（ Indirect Buffer ），而间接缓冲区是间接卷积算法的核心。在网络运行时，每次计算 $M \times N$ 的输出，其中 M 为将 $OH \times OW$ 视作一维后的向量化规模（一般 $M \times N$ 为 4×4 、 8×8 或 4×8 ）。



Indirect Convolution Algorithm 工作流程

- Indirect 算法在输入缓冲区基础上构建间接缓冲区（ Indirect Buffer ），而间接缓冲区是间接卷积算法的核心。在计算 $M \times N$ 规模大小输出时，经由间接缓冲区取出对应输入缓冲区数据，并取出权重，计算出结果，整体计算过程等价于计算 $M \times K$ 和 $K \times N$ 矩阵乘。




Indirect Convolution Algorithm 工作流程

在实现中，软件的执行过程分为两部分：

1. 准备阶段：加载模型，配置输入缓冲区；重排权重，使其内存布局适用于后续计算；
2. 运行阶段：对于每个输入执行 $(OH * OW / M) * (OC / N)$ 次循环，每次使用 GEMM 计算 $M \times N$ 大小输出。


间接缓冲区布局

- 间接缓冲区可以理解为一组卷积核大小的缓冲区，共有 $OH \times OW$ 个，每个缓冲区大小为 $KH \times KW$ （每个缓冲区对应某个输出要使用的输入地址）。每计算一个空间位置输出，使用一个间接缓冲区；空间位置相同而通道不同的输出使用相同间接缓冲区，缓冲区中的每个指针用于索引输入中 IC 个元素。




间接缓冲区布局

- 间接缓冲区可以理解为一组卷积核大小的缓冲区，共有 $OH \times OW$ 个，每个缓冲区大小为 $KH \times KW$ （每个缓冲区对应某个输出要使用的输入地址）。在计算时，随着输出的索引内存地址移动，选用不同的间接缓冲区，即可得到相应的输入地址。无需再根据输出目标的坐标计算要使用的输入的地址，这等同于预先计算地址。



间接缓冲区布局



使用间接缓冲区计算

- 卷积之所以可以使用 Im2col 优化算法，本质原因在于其拆解后忽略内存复用后的计算过程等价于矩阵乘。而间接缓冲区使得可以通过指针模拟出对输入的访存。

优点

- 间接卷积优化算法解决了卷积计算的三个问题，1) 是空间向量化问题，2) 地址计算复杂问题，3) 内存拷贝问题。

缺点

- 通过间接卷积算法，建立的缓冲区和数据重新组织（Repacking）对内存造成大量的消耗。

卷积优化

算法总结

卷积优化总结

- 本文讨论的优化方法都是通用卷积优化方法，随着神经网络处理器（如昇腾 NPU、[寒武纪 MLU](#)、[Google TPU](#)）的发展，以及其他通用计算处理器 GPGPU 的拓展（如点积相关的指令：[Nvidia GPU DP4A](#)、[Intel AVX-512 VNNI](#)、[ARM SDOT/UDOT](#)），深度学习的优化还会继续不断深化和挖掘。

引用

1. <https://zhenhuaw.me/blog/2019/reveal-qnnpack-implementation.html>
2. <https://github.com/pytorch/QNNPACK>
3. <https://arxiv.org/abs/1907.02129>



BUILDING A BETTER CONNECTED WORLD

THANK YOU

Copyright©2014 Huawei Technologies Co., Ltd. All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.